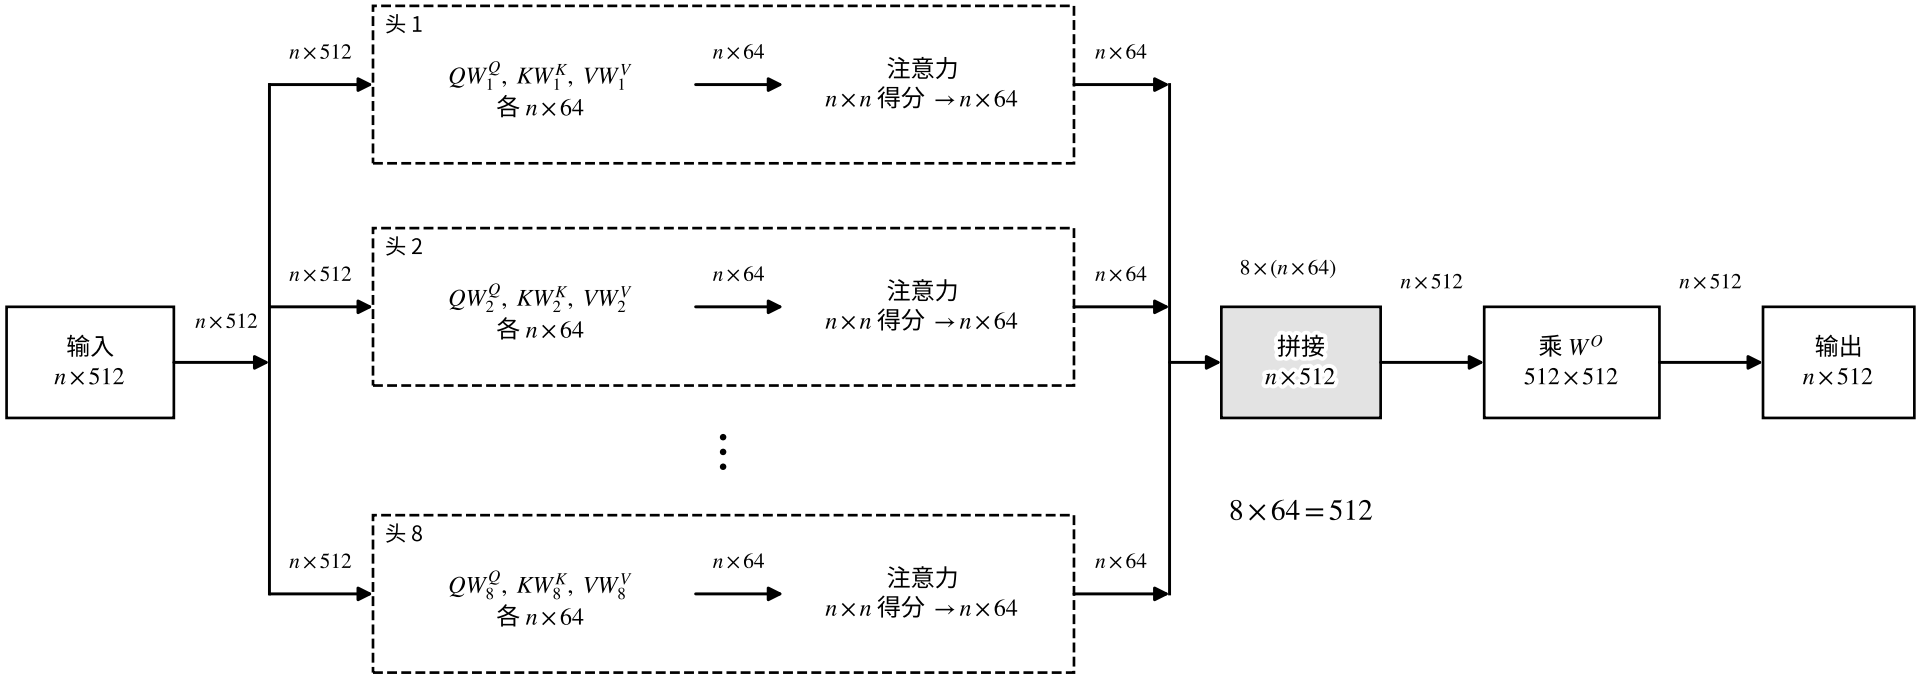

输入
n×512
n×512
头 1
QW_1^Q, KW_1^K, VW_1^V
各 n×64
n×64
注意力
n×n 得分 →n×64
n×64
n×512
头 2
QW_2^Q, KW_2^K, VW_2^V
各 n×64
n×64
注意力
n×n 得分 →n×64
n×64
n×512
头 8
QW_8^Q, KW_8^K, VW_8^V
各 n×64
n×64
注意力
n×n 得分 →n×64
n×64
8×(n×64)
拼接
n×512
n×512
乘 W^O
512×512
n×512
输出
n×512
8×64=512